

深圳大学考试答题纸

(以论文、报告等形式考核专用)
二〇二五~二〇二六学年度第二学期

课程编号 1504550001 课序号 09 课程名称 计算机伦理 主讲教师 ZHANG LIANGJIE 评分

座位号: 68 学号: 2024270223 姓名: 王锦政 专业年级: 2024 级人工智能

教师评语:

题目: AI 智能体的社会影响、伦理风险与治理路径研究

摘要：2025 年以来，人工智能正在由以内容生成为主的工具形态，进一步转向能够感知环境、规划任务、调用工具并执行操作的 AI 智能体系统。AI 智能体的社会意义并不只是效率提升，而在于其开始参与教育、医疗、金融、政务、办公和科研等社会过程，并在部分场景中承担准行动者功能。由此产生的伦理问题也从一般性的模型偏差、隐私泄露和内容失真，扩展为权限边界、行为后果、责任归属和社会信任等复合议题。本文结合《人工智能伦理》课程相关章节，从社会影响、监管与创新、计算机伦理问题以及真实案例四个维度进行分析，提出以风险分级、责任闭环、隐私保护、知识产权协调、公众参与和全生命周期审计为核心的治理路径。

关键词：AI 智能体；人工智能伦理；算法偏见；隐私保护；责任归属；风险治理

一、AI 智能体的技术特征与社会定位

AI 智能体并非传统聊天机器人或单一生成式模型的简单延伸。传统 AI 系统主要围绕问答、推荐、识别或内容生成展开，其行为边界通常限定在模型输出层面；AI 智能体则进一步具备目标理解、任务分解、工具调用、环境反馈和持续执行能力。例如，一个办公智能体可以根据用户目标检索资料、生成文档、发送邮件并维护日程；一个科研智能体可以辅助文献筛选、实验设计和代码调试；一个企业智能体可以与 CRM、ERP、财务系统和客户服务系统连接，参与流程自动化。由此可见，AI 智能体的关键变化在于，它从“提供答案的系统”转向“参与行动的系统”。

课程讲义在第十章[5]指出，人工智能正在使经济活动从数字化阶段进入智能化阶段，其本质差异不只是自动化程度提高，而是经济系统获得学习、预测和主动优化能力。该观点对于理解 AI 智能体尤为重要。AI 智能体将数据、算法与算力组织为持续运行的行动单元，使经济运行单位在某些场景中从岗位、产品或企业流程转向智能体及其组合。与此同时，讲义也提醒，智能体商业模式会带来决策分散化、黑箱风险和责任真空等治理难题。因此，对 AI 智能体的伦理分析不能停留在“是否好用”的层面，而应考察其如何改变组织决策、资源分配和公共信任。

二、AI 智能体的典型应用场景及其正面社会影响

在教育场景中，AI 智能体能够根据学生的学习基础、知识薄弱点和学习节奏提供个性化辅导。与传统在线题库相比，智能体可以动态调整讲解方式，生成针对性练习，并帮助教师完成作业批改、学习诊断和教学资源整理。其正面意义在于降低个性化教育的边际成本，使优质教育资源能够以更灵活的形式触达不同地区和不同基础的学生。对于学习障碍者、偏远地区学生和需要反复练习的群体而言，AI 智能体具有提升教育公平的潜力。[6]

在办公与企业管理场景中，AI 智能体能够承担会议纪要整理、合同初审、客户沟通、数据报表生成和跨系统流程衔接等任务。其价值并不只是节省人工时间，更在于把分散的信息流、审批流和知识流连接起来，减少重复劳动和沟通成本。对于中小企业而言，智能体还可能降低使用专业软件和分析服务的门槛，使组织以较低成本获得过去只有大型企业才能配置的数字化能力。

在医疗和公共服务场景中，AI 智能体可以辅助问诊分诊、慢病随访、影像报告初筛、政策咨询和政务事项办理。若部署得当，它能够缓解基层服务压力，提高公共服务响应速度，并为老年人、残障人士和行动不便者提供更连续的支持。尤其在医疗资源分布不均的情况下，AI 智能体可作为辅助工具帮助患者更早识别风险、获得初步建议并提高就医效率。然而，这类场景也具有高风险属性，智能体不能替代医生、社工或行政责任主体作出最终决定。

在科研与内容生产场景中，AI 智能体可以加速文献检索、代码生成、实验复现、数据清洗和初稿写作。其积极作用在于扩大研究者的认知半径，降低繁琐技术环节对创造性工作的挤压，并促进跨学科协作。课程讲义第十二章[1]强调，AI 伦理需要多学科整合视角，原因正在于 AI 系统的影响同时涉及技术、法律、经济、社会和心理层面。AI 智能体越是深入科研与创作过程，越需要在效率

提升之外建立引用、署名、复核和责任机制。

三、AI 智能体的负面社会影响

AI 智能体的首要风险是错误决策的规模化扩散。普通生成式 AI 的错误往往表现为单次输出失真，而智能体可能把错误理解进一步转化为真实操作，例如误删文件、错误发送邮件、错误提交订单或错误执行金融指令。由于智能体具有连续任务执行能力，一个早期判断偏差可能在后续流程中被放大，最终形成难以及时阻断的连锁后果。课程讲义第十一章关于“实施的脆弱性”的论述表明，即使设计阶段具备伦理原则，若缺乏运行约束和反馈机制，系统仍可能在真实环境中造成严重后果。

第二类风险是隐私泄露与越权访问。AI 智能体为了完成任务，往往需要接入邮件、网盘、浏览器、数据库、支付工具或企业内部系统。若授权机制粗糙，系统可能在用户未充分理解的情况下读取敏感文件、调用联系人信息或跨场景整合个人数据。与传统应用相比，智能体的隐私风险更具隐蔽性，因为用户看到的是自然语言交互界面，而背后发生的是多系统、多权限、多数据源的自动化操作。课程讲义第十一章[6]将隐私保护转化为工程需求，强调最小化数据收集和限制敏感字段可见性，这一思路应成为智能体设计的基本原则。

第三类风险是算法偏见与不公平结果。AI 智能体在招聘、信贷、教育评价、保险定价和公共服务排序等场景中，可能基于历史数据中的结构性偏差作出不利于特定群体的决策。课程讲义第十一章指出[6]，多样性和包容性并非抽象价值口号，而是系统安全性、可靠性和社会接受度的工程前提。若智能体只服务于“典型用户”假设，而未识别所有受影响群体，就可能在规模化部署中持续放大边缘群体的低可见度和不利处境。

第四类风险是就业结构冲击。AI 智能体能够替代部分重复性、流程化和规则明确的知识劳动，例如基础客服、文案初稿、行政处理、初级数据分析和简单代码编写。课程讲义第十章[5]指出，人工智能作为通用目的技术将重塑生产要素、组织形态和劳动分工。对此不能简单地理解为“岗位消失”或“效率提升”，而应看到劳动者技能结构、收入分配和职业尊严都会受到影响。若企业只追求降本增效，而缺乏转岗培训和收益共享机制，智能体应用可能扩大劳动市场的不平等。

第五类风险是安全滥用和信息操控。课程讲义第九章[4]指出，AI 并非简单的犯罪工具，而是通过自主性、规模化和隐蔽性放大风险影响。AI 智能体可被用于自动化钓鱼邮件、批量虚假账号运营、恶意代码生成、深度伪造诈骗和舆论操纵。由于智能体能够连续执行任务并根据反馈调整策略，滥用者不再需要逐步手工操作，犯罪门槛和攻击成本随之下降。此类风险已经超出个人使用规范范畴，成为公共安全与平台治理问题。

四、加强监管与鼓励开放创新之间的平衡

加强监管具有现实必要性。首先，AI 智能体可能进入金融、医疗、教育、政务和基础设施等高风险领域，一旦系统出现错误或被恶意利用，损害对象往往不是单个用户，而是广泛的社会群体。其次，智能体运行涉及数据、权限、模型、插件和第三方工具，责任链条较长，若没有明确监管要求，企业容易以“模型不可控”“用户授权”或“第三方工具错误”为由弱化自身责任。再次，监管能够为市场提供基本秩序，避免企业在竞争压力下通过降低安全测试、扩大数据收集或模糊用户知情权来追求短期增长。

然而，监管也存在潜在风险。若监管标准过于笼统或审批流程过于繁重，可能提高中小企业和开源社区的合规成本，造成创新资源向大型平台集中。若监管过度依赖事前许可，也可能降低技术迭代速度，使有益应用难以及时进入教育、医疗辅助和公共服务场景。因此，AI 智能体监管不宜采取“一刀切”模式，而应根据应用场景、权限范围、影响对象和可逆性进行风险分级。欧盟 AI Act 采用以风险为基础的治理框架[11]，并对不可接受风险、高风险系统和通用人工智能模型设置不同要求，这说明国际治理正在从抽象伦理宣示转向分层监管。

鼓励开放创新同样具有重要意义。开放模型、开放工具链和开放评测能够降低技术门槛，促进

研究复现，推动教育、科研和中小企业应用发展。开源社区还能够通过外部审查发现安全漏洞和偏见问题，避免关键能力完全被少数商业平台垄断。课程讲义第八章[3]关于开源、闭源与知识产权策略的讨论表明，技术开放并非单纯的商业选择，而是创新激励、公共监督和风险承担之间的制度安排。

但是，开放创新也可能带来滥用扩散。高度开放的智能体框架若缺少安全边界，可能被用于自动化攻击、诈骗脚本生成和违法内容生产。模型权重、插件接口和工具调用能力的开放程度越高，越需要配套身份验证、速率限制、危险能力评估、使用日志和滥用响应机制。因此，合理路径不是在监管与创新之间二选一，而是建立“高风险严格约束、低风险鼓励试验、通用能力持续评估、开放生态责任共担”的治理结构。

五、计算机伦理视角下的关键问题

从 IT 职业道德与社会责任角度看，AI 智能体要求从业者重新理解自身职业身份。课程讲义第七章[2]指出，AI 从业者已经从特定技术模块的实现者转变为影响社会资源分配、公共决策质量和人机关系的重要行动者。传统软件工程中，开发者的责任往往围绕功能实现、性能优化和系统稳定展开；而在 AI 智能体系统中，数据选择、优化目标、权限设计、提示词约束、工具调用规则和异常处理逻辑都会影响真实社会后果。因此，开发者不能以“技术中立”回避责任，而应把伦理判断力视为专业能力的一部分。

从隐私保护角度看，AI 智能体的核心问题是授权是否真实、必要、可撤回和可审计。传统隐私治理主要关注数据收集和存储，智能体治理还必须关注数据被何种任务调用、在何种工具之间流转、是否进入模型上下文、是否被长期记忆保存以及是否被第三方插件访问。隐私保护不能只依赖用户勾选同意条款，而应落实为默认最小权限、敏感操作二次确认、任务级授权、日志可查询和数据生命周期管理。课程讲义第十一章[6]强调，伦理原则必须转化为代码结构、系统接口和运行流程，否则容易停留在纸面宣示。这一观点对 AI 智能体尤为关键。

从知识产权角度看，AI 智能体改变了创作、检索、改写和生产的边界。课程讲义第八章[3]指出，传统知识产权制度以人类创造性劳动为核心前提，而 AI 的介入使作品、发明、模型、数据和系统能力交织在一起。智能体在生成论文草稿、商业文案、设计方案或代码时，可能涉及训练数据来源、输出内容相似性、用户贡献、平台贡献和模型开发者贡献等多重权利关系。如果缺乏透明标注和来源管理，智能体可能造成侵权风险、署名争议和学术不端。未来治理需要在保护原创者权益、鼓励合理使用和促进技术创新之间建立更精细的规则。

从算法公平角度看，AI 智能体的偏见不只来自模型本身，也来自任务目标和工具链。例如，一个招聘智能体若以历史高绩效员工画像作为筛选标准，可能把过去组织中的性别、年龄或学历偏见重新包装为“数据驱动决策”。一个教育评价智能体若只根据可量化行为判断学生能力，可能忽视家庭环境、语言背景和身心差异。公平治理需要覆盖数据采集、特征选择、模型评估、交互设计和申诉机制，而不能只在模型发布前做一次性测试。

从责任归属角度看，AI 智能体最具挑战的问题是主体协同下的责任扩散。一个智能体造成损害时，相关主体可能包括模型提供者、插件开发者、部署企业、数据提供者、终端用户和监管机构。若没有预先界定责任边界，损害发生后容易出现互相推诿。课程讲义第十章指出，智能体组合会带来决策分散化与责任真空；第九章又强调，安全治理需要通过审计机制形成责任闭环。因此，AI 智能体治理必须坚持“谁部署、谁管理；谁获益、谁担责；谁控制关键风险，谁承担相应义务”的基本原则。

六、真实案例分析

第一个案例是 Air Canada 聊天机器人误导消费者事件[8]。2024 年 2 月，加拿大不列颠哥伦比亚省民事解决 tribunal 在 Moffatt v. Air Canada 案中认定，Air Canada 应对其网站聊天机器人提供

的错误丧亲票价退款信息承担责任。消费者依据聊天机器人说明购买机票并申请退款，但航空公司随后以正式政策不支持该申请为由拒绝。该案的重要意义在于，企业不能将聊天机器人视为独立责任主体，也不能以网页其他位置存在准确信息来否定其自动化系统造成的误导。对于 AI 智能体治理而言，该案说明只要系统以企业名义向公众提供服务，企业就负有保证信息准确、设置纠错机制和承担损害后果的义务。

第二个案例是 Amazon 招聘算法偏见事件[9]。据 Reuters 2018 年报道，Amazon 曾开发用于筛选简历的 AI 招聘工具，但由于系统从过去十年主要由男性占多数的技术岗位简历中学习，模型倾向于降低包含女性相关表述的简历评分。该事件说明，算法偏见并不一定来自开发者的显性歧视，也可能来自历史数据中的结构性不平等。若类似系统升级为招聘智能体，并进一步承担候选人筛选、面试安排和评价汇总功能，其不公平影响将更难被个体发现和纠正。因此，高风险人事决策场景必须设置人工复核、群体公平评估、候选人申诉渠道和第三方审计。

第三个案例是香港 Deepfake 视频会议诈骗事件[10]。2024 年 2 月，香港警方披露，一家跨国公司香港分支机构员工在视频会议中遭遇深度伪造诈骗，犯罪者伪装为公司高管和同事，诱导其转账约 2 亿港元，约合 2560 万美元。该事件体现了 AI 滥用从单一伪造内容向实时交互式欺骗升级的趋势。若未来犯罪者结合 AI 智能体进行目标筛选、话术生成、身份伪装和资金流转，诈骗将呈现更强的自动化和组织化特征。因此，企业不能只依赖员工肉眼识别视频真伪，而应建立多因素验证、异常交易阻断、跨渠道确认和深度伪造检测机制。

七、未来 AI 智能体伦理治理策略

未来 AI 智能体治理应以风险分级为基础。低风险场景如个人写作辅助、日程整理和公开资料检索，可以采取相对宽松的创新环境，但仍需保证用户知情、数据可控和输出可追溯。中风险场景如企业流程自动化、客户服务和教育辅助，应要求权限管理、日志留存、错误纠正和人工复核。高风险场景如医疗建议、金融交易、招聘筛选、政务服务和公共安全，则必须进行事前评估、独立审计、持续监测和责任备案。风险分级的重点不是限制技术，而是使治理强度与潜在损害相匹配。

AI 智能体必须坚持人类最终责任原则。智能体可以执行任务，但不能成为法律和伦理责任的替代主体。凡涉及资金转移、医疗判断、劳动权益、教育评价、法律后果和公共资源分配的事项，都应设置明确的人类责任人和可解释的决策记录。对用户而言，系统应清楚标明哪些行为由智能体建议，哪些行为由智能体自动执行，哪些行为需要人工确认。对企业而言，不能把“AI 出错”作为免责理由，而应承担部署、测试、监控和纠错责任。

隐私保护应从“同意模式”升级为“权限治理模式”。AI 智能体每一次调用邮件、文件、通讯录、位置、支付工具或企业数据库，都应遵循任务必要性原则。系统应支持细粒度授权，例如只允许读取某一文件夹、只允许在当前任务中使用数据、只允许生成草稿而不允许自动发送。对于敏感数据，智能体应默认采用脱敏、加密、最短保存周期和本地优先处理策略。用户还应能够查看智能体使用过哪些数据、调用过哪些工具以及执行过哪些操作。

知识产权治理应建立来源标注与生成边界机制。用于学术写作、新闻生产、代码开发和商业设计的智能体，应记录关键素材来源、提示用户核验引用，并避免将生成内容伪装为完全原创。教育场景应明确区分辅助学习、文本润色和代写作弊；科研场景应要求披露 AI 工具参与方式；企业场景应对训练数据、第三方素材和开源许可证进行合规审查。这样既能保护原创者权益，也能避免因过度封闭而抑制合理创新。

安全治理应采用全生命周期审计。AI 智能体上线前需要完成危险能力评估、红队测试、权限边界测试和滥用场景推演；上线后需要持续监测异常调用、越权访问、批量操作、欺诈模式和用户投诉；发生事故后需要能够追踪日志、定位责任并及时修复。NIST AI Risk Management Framework [12] 将可信 AI 的特征概括为有效可靠、安全、稳健、可问责、透明、可解释、隐私增强以及有害偏见可管理，这些原则可作为智能体审计指标体系的重要参考。

公众参与是 AI 智能体治理不可缺少的社会条件。课程讲义第十三章[7]指出，公众既是风险的

直接承担者，也是伦理规范的现实检验者和可接受技术边界的定义者。AI 智能体越深入日常生活，越不能只由专家、企业和监管部门闭门决定其边界。应通过公开说明、用户反馈、社会听证、行业标准和宣传教育提升公众参与能力。公众不需要理解所有模型细节，但有权知道系统是否使用 AI、是否自动决策、是否影响个人权益以及如何提出异议。

八、AI 智能体治理的落地保障

AI 智能体治理要真正发挥作用，不能只停留在制度文本和原则表述层面，而应转化为可执行、可检查、可追责的组织流程。首先，部署单位应在系统上线前完成场景分类和权限清单梳理，明确智能体可以访问哪些数据、调用哪些工具、执行哪些操作以及哪些操作必须经过人工确认。对于邮件发送、资金支付、合同修改、成绩评价、医疗建议等高影响行为，应将“默认不自动执行”作为基本设计原则，并通过二次确认、审批流和异常阻断机制降低误操作风险。其次，系统运行过程应保留必要日志，包括任务目标、关键提示、工具调用、数据访问、人工确认记录和错误处理结果。日志保存并不是为了无限扩大监控，而是为了在发生争议、损害或安全事件时能够还原事实链条，避免责任在模型提供者、部署单位、插件开发者和终端用户之间被稀释。

其次，AI 智能体治理需要形成持续评估机制。传统软件系统通常在上线前完成测试即可进入稳定维护阶段，但智能体系统会随着模型更新、插件扩展、用户行为变化和外部环境变化而产生新的风险。因此，治理不能被理解为一一次性合规检查，而应被设计为周期性评估。部署单位可以围绕准确性、稳定性、公平性、隐私保护、安全性、可解释性和用户满意度建立指标体系，并将不同风险等级对应到不同频率的审查要求。低风险办公助手可以主要关注误报率、用户撤回率和数据最小化情况；中风险企业智能体应增加权限审计、异常调用检测和人工复核比例；高风险医疗、金融、招聘和政务智能体则应接受独立评估，并保留外部监督和申诉通道。这样的动态治理思路与课程讲义第十一章关于“全生命周期渗透”和“可验证、可追责机制”的要求是一致的。

再次，治理策略还应关注组织内部的责任文化。AI 智能体往往被包装为提升效率的工具，容易使使用者低估其社会后果。若企业或学校只强调“提高产出”，而不强调核验、审慎和责任承担，智能体就可能诱导用户形成过度依赖。以高校学习场景为例，学生使用智能体辅助资料检索、语言润色和结构梳理具有合理性，但若直接由智能体代写论文或伪造引用，就会损害学术诚信。教师和学校不应简单禁止所有 AI 使用，而应区分学习辅助、写作支持和学术替代，建立明确的披露规则和评价标准。对企业而言，也应通过培训使员工理解智能体输出并非事实本身，所有涉及外部承诺、客户权益和法律后果的内容都必须由责任人复核。职业伦理由此不再只是开发者的义务，也成为管理者、使用者和组织共同承担的实践要求。

最后，未来治理还需要在技术标准、行业规范和公共教育之间形成协同。单个企业可以改进自身产品，但很难独立解决跨平台滥用、深度伪造传播、数据来源不透明和模型责任边界模糊等问题。行业层面应推动智能体能力分级、接口安全标准、插件审核标准和事故通报机制；监管层面应针对高风险场景建立备案、审计和责任追溯要求；公共教育层面则应提升普通用户对 AI 输出、自动化决策和深度伪造内容的识别能力。课程讲义第十三章强调，公众并非被动承受技术后果的对象，而是伦理规范的现实检验者和技术边界的共同定义者。只有当技术开发者、部署机构、监管部门和公众之间形成稳定反馈循环，AI 智能体治理才可能从事后补救转向事前预防，从个案处理转向制度化能力建设。

九、结论

AI 智能体的发展使人工智能伦理进入新的阶段。它既能提高效率、降低服务成本、促进个性化学习、增强弱势群体服务能力，也可能造成错误决策、隐私泄露、算法歧视、就业冲击、责任不清和安全滥用。其治理难点不在于单一模型是否准确，而在于智能体已经嵌入真实社会流程，能够把模型输出转化为可执行行动。因此，未来治理不能停留在抽象原则层面，而应将伦理要求写入工程架构、组织流程、法律责任和公共参与机制之中。

本文认为，AI 智能体的合理治理应遵循“审慎监管与开放创新并重”的路径。一方面，对于高风险场景必须建立严格的评估、审计、问责和人工复核机制；另一方面，对于低风险和公共利益明显的场景，应保留开放试验和技术创新空间。真正可持续的 AI 智能体治理，不是压制技术发展，而是使技术发展获得社会正当性。只有当效率、权利、安全、公平和责任被同时纳入系统设计，AI 智能体才能从单纯的自动化工具转化为值得信任的社会技术基础设施。

参考文献

- [1] 张良杰：《人工智能伦理》课程讲义，引言：AI 重新定义计算，开启全息计算伦理新纪元，深圳大学，2026。
- [2] 张良杰：《人工智能伦理》第七章：AI 职业的伦理与责任（职业篇），深圳大学，2026。
- [3] 张良杰：《人工智能伦理》第八章：人工智能时代的知识产权重构（法律篇），深圳大学，2026。
- [4] 张良杰：《人工智能伦理》第九章：对抗 AI 犯罪与滥用（安全篇），深圳大学，2026。
- [5] 张良杰：《人工智能伦理》第十章：人工智能的经济影响与未来图景（经济篇），深圳大学，2026。
- [6] 张良杰：《人工智能伦理》第十一章：伦理在 AI 实施中的角色（实施篇），深圳大学，2026。
- [7] 张良杰：《人工智能伦理》第十三章：公众在人工智能伦理中的作用（公众篇），深圳大学，2026。
- [8] British Columbia Civil Resolution Tribunal, *Moffatt v. Air Canada*, 2024 BCCRT 149. 相关介绍参见 American Bar Association: https://www.americanbar.org/groups/business_law/resources/business-law-today/2024-february/bc-tribunal-confirms-companies-remain-liable-information-provided-ai-chatbot/
- [9] Reuters, Amazon scraps secret AI recruiting tool that showed bias against women, 2018. 相关转载与摘要参见 MediaWell: <https://mediawell.ssrc.org/news-items/amazon-scraps-secret-ai-recruiting-tool-that-showed-bias-against-women-reuters/>
- [10] South China Morning Post, Multinational firm's Hong Kong office loses HK\$200 million after scammers stage deepfake video conference, 2024. <https://www.scmp.com/news/hong-kong/law-and-crime/article/3250851/every-one-looked-real-multinational-firms-hong-kong-office-loses-hk200-million-after-scammers-stage>
- [11] European Commission, AI Act. <https://digital-strategy.ec.europa.eu/en/policies/regulatory-framework-ai>
- [12] National Institute of Standards and Technology, AI Risk Management Framework. <https://www.nist.gov/itl/ai-risk-management-framework>

AI 工具使用说明：本文使用 AI 工具辅助完成资料梳理、结构组织。报告观点根据作业要求、课程讲义与公开资料综合形成，案例事实和参考文献已在文中及文末注明。